

Поиск ассоциативных правил алгоритмом Apriori

1. Формулировка задания

Требуется дополнить программу поиска частых наборов генерацией ассоциативных правил. Каждое правило должно выводиться в виде «антецедент $\rightarrow$ консеквент» вместе с поддержкой и достоверностью. Пользователь задаёт пороги поддержки и достоверности, а также выбирает сортировку по убыванию поддержки или лексикографически.

На исходном наборе `baskets.csv` нужно зафиксировать поддержку, изменить порог достоверности, измерить время поиска и число правил. Результаты необходимо показать на двух диаграммах. Также требуется подготовить список правил, содержащих суммарно не более семи объектов, и объяснить их практический смысл.

2. Репозиторий и материалы

Исходный код, набор данных, полные результаты, рисунки и отчёт размещены в репозитории:

<https://github.com/Queenace/Fundamentals-of-Data-Mining/tree/main/2>.

Основная программа находится в файле `apriori.py`. Эксперименты выполняет `rule_experiments.py`, а диаграммы строятся функцией `save_rule_charts` из `plots.py`. Полные списки правил сохранены в каталоге `results` в двух вариантах сортировки.

3. Метод поиска правил

Сначала алгоритм Apriori находит частые наборы. Для каждого частого набора L длиной не менее двух программа перебирает все непустые собственные подмножества A . Подмножество A становится антецедентом, а оставшиеся товары образуют консеквент B . Так получается правило $A \rightarrow B$.

Поддержка правила равна доле корзин, которые содержат все товары из A и B . Достоверность показывает, в какой доле корзин с антецедентом A также встречается консеквент B . Она вычисляется как отношение поддержки совместного набора A и B к поддержке A . Правило сохраняется, если его достоверность не меньше заданного порога.

В текстовом режиме программа печатает правило, поддержку и достоверность. Формат JSON дополнительно содержит обе части правила как списки, абсолютное число корзин и суммарную длину. Параметр `max-rule-length` позволяет ограничить число объектов. Сортировка `support` сначала учитывает поддержку, затем достоверность. Сортировка `lex` сравнивает антецедент и консеквент по названиям товаров.

4. Постановка экспериментов

В файле 7501 корзина. Поддержка зафиксирована на уровне 1%. При этом найдено 261 частый набор, а максимальная длина набора равна 3. Порог достоверности изменялся от 20% до 50% с шагом 5%.

Пример из задания с диапазоном от 70% до 95% для этих данных не подходит. Максимальная достоверность среди правил с поддержкой 1% составляет 50,67%, поэтому при каждом пороге от 70% получился бы нулевой результат. Диапазон от 20% до 50% показывает реальное изменение числа правил.

Для каждого порога выполнен один прогрев и 100 измерений. Порядок 700 запусков перемешан с seed=42. В измеряемый участок входят генерация, фильтрация и сортировка правил. Поиск частых наборов выполняется один раз до измерений, потому что при фиксированной поддержке он не зависит от порога достоверности.

Порог, %	Медиана, мс	Минимум, мс	Максимум, мс	Правил
20%	0,420	0,399	0,556	164
25%	0,384	0,365	0,481	99
30%	0,368	0,351	0,596	65
35%	0,353	0,337	0,527	34
40%	0,346	0,329	0,440	19
45%	0,342	0,323	0,447	6
50%	0,342	0,322	0,441	2




Рисунок 1. Время генерации, фильтрации и сортировки правил при изменении порога достоверности.

Медианное время уменьшается с 0,420 мс при пороге 20% до 0,342 мс при пороге 50%. Разница небольшая, потому что программа в любом случае рассматривает одни и те же разбиения частых наборов. Более высокий порог сокращает число объектов, которые нужно добавить в результат и отсортировать.

Измеренные значения меньше одной миллисекунды и зависят от компьютера и фоновой нагрузки. Они показывают тенденцию для этой реализации, но не являются универсальной оценкой скорости Apriori.

Количество найденных правил




Рисунок 2. Количество правил при изменении порога достоверности.

Количество правил последовательно сокращается: 164, 99, 65, 34, 19, 6 и 2. Это ожидаемый результат. Любое правило, которое проходит высокий порог, проходит и все более низкие пороги. Поэтому множество правил при увеличении confidence может только уменьшаться.

Порог 20% даёт большой список, в котором сложнее выделить главное. Порог 50% оставляет только два правила. Для содержательного анализа выбран промежуточный порог 40%. Он даёт 19 правил, поэтому список остаётся обозримым и сохраняет несколько разных типов покупательского поведения.

5. Список правил и содержательный анализ

Ниже приведены все правила при поддержке 1% и достоверности 40%. Антецедент и консеквент суммарно содержат не более семи объектов. Фактически максимальная длина равна трём, потому что при поддержке 1% частые наборы большей длины в baskets.csv отсутствуют.

Правило	Поддержка	Достоверность
говяжий фарш → минеральная вода	4,093%	41,655%
говяжий фарш → макароны	4,026%	40,977%
оливковое масло → минеральная вода	2,760%	41,903%
суп → минеральная вода	2,306%	45,646%
говяжий фарш, макароны → минеральная вода	1,720%	42,715%
говяжий фарш, минеральная вода → макароны	1,720%	42,020%
лосось → минеральная вода	1,706%	40,125%
макароны, шоколад → минеральная вода	1,640%	40,196%
макароны, молоко → минеральная вода	1,613%	43,682%
молоко, шоколад → минеральная вода	1,400%	43,568%
шоколад, яйца → минеральная вода	1,346%	40,562%
молоко, яйца → минеральная вода	1,306%	42,424%
замороженные овощи, макароны → минеральная вода	1,227%	43,396%
блинчики, макароны → минеральная вода	1,173%	45,833%
говяжий фарш, молоко → минеральная вода	1,107%	50,303%
замороженные овощи, молоко → минеральная вода	1,107%	46,893%
говяжий фарш, шоколад → минеральная вода	1,093%	47,399%
макароны, оливковое масло → минеральная вода	1,067%	44,944%
говяжий фарш, яйца → минеральная вода	1,013%	50,667%

Большинство правил указывает на минеральную воду в консеквенте. Например, правило «суп → минеральная вода» имеет поддержку 2,306% и достоверность 45,646%. Это означает, что оба товара встречаются вместе

примерно в 2,3% всех корзин, а среди корзин с супом минеральная вода присутствует примерно в 45,6% случаев.

Самые достоверные правила связаны с сочетаниями из двух товаров. Для «говяжий фарш, яйца → минеральная вода» достоверность равна 50,667%, а для «говяжий фарш, молоко → минеральная вода» она равна 50,303%. Такие правила могут использоваться для совместного размещения товаров или рекомендаций, однако их поддержка составляет около 1%, поэтому они описывают сравнительно небольшую часть покупок.

Правило «говяжий фарш → макароны» выделяется тем, что его консеквентом является не минеральная вода. Поддержка равна 4,026%, достоверность 40,977%. Это одно из наиболее распространённых правил в списке и оно отражает понятное сочетание продуктов для приготовления основного блюда.

Высокая доля правил с минеральной водой частично объясняется её общей популярностью: она встречается в 23,837% всех корзин. Поэтому confidence нельзя понимать как доказательство причинной связи. Для оценки силы связи полезно дополнительно вычислять lift и сравнивать достоверность с базовой частотой консеквента, хотя это не входило в задание.

6. Вывод

Программа дополнена поиском ассоциативных правил, порогом достоверности, ограничением длины и двумя способами сортировки. Правильность поддержки и достоверности 19 анализируемых правил независимо проверена прямым просмотром корзин. Эксперимент показал, что повышение порога достоверности с 20% до 50% сокращает число правил со 164 до 2 и немного уменьшает время формирования результата.

[1] Agrawal R., Srikant R. Fast Algorithms for Mining Association Rules in Large Databases. VLDB, 1994, страницы с 487 по 499. Текст статьи.