

Лабораторная работа 3. Классификация деревьев решений

1. Формулировка задания

Требуется построить классификатор годового дохода на данных Census Income. Пользователь выбирает критерий разбиения: информационный выигрыш, отношение выигрыша или индекс Джини. Нужно обучить деревья на 100% исходной обучающей выборки, проверить их на отдельной тестовой выборке и показать структуру деревьев.

Затем программа должна принимать долю обучающей выборки и рассчитывать аккуратность, точность, полноту и F-меру. Для одного критерия необходимо сравнить доли обучения 60%, 70%, 80% и 90% и построить диаграмму качества.

2. Репозиторий и данные

Исходный код, файлы UCI, рисунки, подробные результаты и отчёт находятся в каталоге <https://github.com/Queeenace/Fundamentals-of-Data-Mining/tree/main/3>.

Использованы файлы adult.data (32 561 запись), adult.test (16 281 запись) и adult.names из архива UCI. Метка «>50K» считается положительным классом. Точка в конце метки в adult.test удаляется при чтении. Значение «?» остаётся отдельной категорией.

3. Метод и постановка опыта

Числовые признаки сравниваются с порогами, категориальные кодируются отдельными двоичными признаками. Кодировщик обучается только на обучающей части. Для числового признака проверяются 32 квантильных порога. Дерево ограничено глубиной 6 и содержит не менее 120 наблюдений в каждом листе. Эти ограничения уменьшают переобучение и делают схему обозримой.

Информационный выигрыш оценивает снижение энтропии. Gain ratio делит выигрыш на энтропию самого разбиения и тем самым меняет оценку кандидатов. Критерий Джини оценивает уменьшение неоднородности классов. Все три критерия реализованы в одном алгоритме дерева.


Для первого опыта использованы все 32 561 строки исходного файла обучения; качество измерено на отдельном файле adult.test. Для второго опыта только adult.data делится на обучающую и тестовую части с сохранением доли классов и фиксированным seed=42. Критерий второго опыта - индекс Джини. Положительный класс во всех расчётах один и тот же: доход выше 50 000 долларов.

4. Качество при полном исходном обучении

Критерий	Аккуратность, %	Точность, %	Полнота, %	F-мера, %
Information gain	84,53	77,74	48,39	59,65
Gain ratio	84,38	74,63	51,33	60,82
Gini index	84,53	78,13	47,92	59,40

На отдельном тестовом файле аккуратность всех трёх деревьев составляет около 84,4–84,5%. Различия лучше видны в структуре разбиений и балансе точности и полноты.


Рисунок 1. Верхние уровни дерева по критерию Information gain.



На схеме показаны первые три уровня. Надпись «ветвь продолжается» означает, что в полном дереве есть следующие разбиения. Число n обозначает количество записей в узле, а $>50K$ - количество представителей положительного класса. Полная структура дерева с порогами сохранена в каталоге results в формате JSON.

У разных критериев могут отличаться первые выбранные признаки и следующие пороги. Поэтому близкие итоговые оценки качества не означают, что построенные деревья одинаковы.


Рисунок 2. Верхние уровни дерева по критерию Gain ratio.



На схеме показаны первые три уровня. Надпись «ветвь продолжается» означает, что в полном дереве есть следующие разбиения. Число n обозначает количество записей в узле, а >50K - количество представителей положительного класса. Полная структура дерева с порогами сохранена в каталоге results в формате JSON.

Gain ratio сначала отделяет записи с большим приростом капитала. В этой группе доля доходов выше 50 000 долларов особенно высока. При небольшом приросте капитала дерево далее учитывает семейное положение и образование. Это описание статистических связей, а не причин дохода.

Рисунок 3. Верхние уровни дерева по критерию Gini index.



На схеме показаны первые три уровня. Надпись «ветвь продолжается» означает, что в полном дереве есть следующие разбиения. Число n обозначает количество записей в узле, а $>50K$ - количество представителей положительного класса. Полная структура дерева с порогами сохранена в каталоге results в формате JSON.

У разных критериев могут отличаться первые выбранные признаки и следующие пороги. Поэтому близкие итоговые оценки качества не означают, что построенные деревья одинаковы.

5. Влияние доли обучающей выборки




Рисунок 4. Показатели качества дерева при разных долях обучающей выборки.

Аккуратность увеличилась с 84,50% при доле обучения 60% до 85,48% при 90%. F-мера выросла с 60,91% до 62,67%. Полнота остаётся около 50%, поэтому примерно половина людей с высоким доходом не определяется как положительный класс.

При увеличении доли обучения тестовая часть становится меньше. По четырём точкам нельзя утверждать, что рост продолжится. Для сравнения с ансамблем используется разбиение 80% / 20% и те же исходные строки.