

Лабораторная работа 5. Разделительная кластеризация

Формулировка задания. Разработать программу кластеризации методом k-Means и k-Medoids. Для набора клиентов банка исследовать зависимость ошибки от числа кластеров, добавить случайное изменение заданной доли объектов и показать результаты на диаграммах.

Материалы. Исходный код, набор данных, результаты экспериментов и рисунки размещены в [каталоге лабораторной работы 5 на GitHub](#).

Данные и методика. В файле 850 клиентов. Для расчётов взяты возраст, образование, стаж, доход, долг по карте, прочие долги и отношение долга к доходу. Порядковый номер и идентификатор исключены, поскольку они не описывают сходство клиентов. Поле Defaulted пропущено: у 150 записей нет значения. Перед кластеризацией признаки стандартизированы по среднему и стандартному отклонению исходного набора.

При каждом уровне шума случайно выбирается ровно заданная доля клиентов, а один или несколько их признаков изменяются случайной величиной.

Зафиксированное зерно генератора делает опыты воспроизводимыми.

Проверены k от 3 до 9 и доли шума 0%, 1%, 3%, 5%, 10%. Ошибка на диаграмме означает среднее евклидово расстояние объекта до назначенного центра k-Means или медоида k-Medoids в стандартизованном пространстве.




Рисунок 1. Ошибка кластеризации при разном числе кластеров и уровне шума.

При увеличении k ошибка уменьшается у обоих алгоритмов: каждый объект получает более близкого представителя. Для k=5 без шума получено 1,643 у k-Means и 1,704 у k-Medoids. При шуме 10% эти значения выросли до 1,669 и 1,740 соответственно. Рост небольшой, поскольку изменяется лишь часть

объектов и масштаб возмущения ограничен.




Рисунок 2. Проекция клиентов на две главные компоненты при $k=5$; цвет показывает назначенный кластер.

На рисунке показана двумерная проекция семи признаков, поэтому близкие точки на рисунке не обязательно совпадают по всем исходным координатам. В варианте k-Means без шума самый большой кластер включает 383 клиента и имеет средний доход 28,1 тыс. долларов в год, а небольшой кластер из 42 клиентов имеет средний доход 139,1 тыс. долларов. Такое разделение показывает влияние дохода и долговой нагрузки, но само по себе не означает причинной связи или оценки кредитного риска.

k-Medoids выбирает представителями реальные записи клиентов, а k-Means использует средние координаты. По полученным данным k-Means дал меньшую среднюю ошибку на выбранных значениях k . Цветовые номера кластеров между отдельными запусками не сопоставляются напрямую.