

Лабораторная работа 6. Иерархическая кластеризация

Формулировка задания. Разработать программу иерархической кластеризации с выбором связи между кластерами. Построить дендрограммы, сравнить single, complete, average и Ward на наборе клиентов банка, а также сопоставить результат с разделительной кластеризацией.

Материалы. Программа, результаты и рисунки находятся в [каталоге лабораторной работы 6 на GitHub](#). Исходный набор клиентов находится в соседнем каталоге лабораторной работы 5.

Данные и методика. Использованы те же 850 клиентов и семь стандартизованных числовых признаков, что в лабораторной работе 5. Расстояние между объектами евклидово. Для каждого способа связи построена полная иерархия. Дендрограммы показывают последние 35 слияний, чтобы сохранить читаемость; число объектов в свёрнутой ветви указано рядом с ней. Деревья разрезаны на k кластеров, где k принимает значения от 3 до 9.




Рисунок 1. Дендрограмма для single linkage.




Рисунок 2. Дендрограмма для complete linkage.




Рисунок 3. Дендрограмма для group average.




Рисунок 4. Дендрограмма для Ward.

Форма деревьев различается. Single linkage соединяет группы по ближайшей паре точек и склонен образовывать длинные цепочки. При $k=5$ он поместил 846 клиентов в один кластер, а ещё четырёх выделил по одному. Average также оставил 833 клиента в одной группе. Complete дал два крупных кластера на 578 и 260 клиентов и три маленькие группы. Ward дал более сбалансированное разбиение: 495, 157, 105, 81 и 12 клиентов.




Рисунок 5. Цветом показаны кластеры четырёх методов при $k=5$.

Для сравнения использовано среднее расстояние до центроида назначенного кластера на одинаково стандартизованных признаках. При $k=5$ оно составило 2,261 для single, 1,978 для complete, 2,186 для average и 1,732 для Ward. Значения 1,643 у k-Means и 1,704 у k-Medoids из лабораторной работы 5 рассчитаны относительно их собственных представителей. На сравнительном графике для всех методов расстояние пересчитано именно до центроидов.




Рисунок 6. Среднее расстояние до центроида при разных k; кресты отмечают разделительные методы при k=5.

Разбиение Ward ближе к k-Means, чем остальные иерархические разбиения: индекс Рэнда с поправкой равен 0,591 при k=5. У single и average он близок к нулю, что соответствует преобладанию одного крупного кластера.

Коэффициент силуэта у single равен 0,640, но его нельзя трактовать отдельно от размера кластеров: четыре из пяти групп содержат по одному объекту. Для содержательного описания клиентов в этом опыте Ward и разделительные методы дают более полезное разбиение.