

# Поиск ассоциативных правил алгоритмом Apriori

## 1. Формулировка задания

Требуется дополнить программу поиска частых наборов генерацией ассоциативных правил. Каждое правило должно выводиться в виде «антецедент  $\rightarrow$  консеквент» вместе с поддержкой и достоверностью. Пользователь задаёт пороги поддержки и достоверности, а также выбирает сортировку по убыванию поддержки или лексикографически.

На исходном наборе `baskets.csv` нужно зафиксировать поддержку, изменить порог достоверности, измерить время поиска и число правил. Результаты необходимо показать на двух диаграммах. Также требуется подготовить список правил, содержащих суммарно не более семи объектов, и объяснить их практический смысл.

## 2. Репозиторий и материалы

Исходный код, набор данных, полные результаты, рисунки и отчёт размещены в репозитории:

<https://github.com/Queenace/Fundamentals-of-Data-Mining>.

Основная программа находится в файле `apriori.py`. Эксперименты выполняет `rule_experiments.py`, а диаграммы строятся функцией `save_rule_charts` из `plots.py`. Полные списки правил сохранены в каталоге `results` в двух вариантах сортировки.

## 3. Метод поиска правил

Сначала алгоритм Apriori находит частые наборы. Для каждого частого набора  $L$  длиной не менее двух программа перебирает все непустые собственные подмножества  $A$ . Подмножество  $A$  становится антецедентом, а оставшиеся товары образуют консеквент  $B$ . Так получается правило  $A \rightarrow B$ .

Поддержка правила равна доле корзин, которые содержат все товары из  $A$  и  $B$ . Достоверность показывает, в какой доле корзин с антецедентом  $A$  также встречается консеквент  $B$ . Она вычисляется как отношение поддержки совместного набора  $A$  и  $B$  к поддержке  $A$ . Правило сохраняется, если его достоверность не меньше заданного порога.

В текстовом режиме программа печатает правило, поддержку и достоверность. Формат JSON дополнительно содержит обе части правила как списки, абсолютное число корзин и суммарную длину. Параметр `max-rule-length` позволяет ограничить число объектов. Сортировка `support` сначала учитывает поддержку, затем достоверность. Сортировка `lex` сравнивает антецедент и консеквент по названиям товаров.

#### 4. Постановка экспериментов

В файле 7501 корзина. Поддержка зафиксирована на уровне 1%. При этом найдено 261 частый набор, а максимальная длина набора равна 3. Порог достоверности изменялся от 20% до 50% с шагом 5%.

Пример из задания с диапазоном от 70% до 95% для этих данных не подходит. Максимальная достоверность среди правил с поддержкой 1% составляет 50,67%, поэтому при каждом пороге от 70% получился бы нулевой результат. Диапазон от 20% до 50% показывает реальное изменение числа правил.

Для каждого порога выполнен один прогрев и 100 измерений. Порядок 700 запусков перемешан с seed=42. В измеряемый участок входят генерация, фильтрация и сортировка правил. Поиск частых наборов выполняется один раз до измерений, потому что при фиксированной поддержке он не зависит от порога достоверности.

| Порог, % | Медиана, мс | Минимум, мс | Максимум, мс | Правил |
|----------|-------------|-------------|--------------|--------|
| 20%      | 0,420       | 0,399       | 0,556        | 164    |
| 25%      | 0,384       | 0,365       | 0,481        | 99     |
| 30%      | 0,368       | 0,351       | 0,596        | 65     |
| 35%      | 0,353       | 0,337       | 0,527        | 34     |
| 40%      | 0,346       | 0,329       | 0,440        | 19     |
| 45%      | 0,342       | 0,323       | 0,447        | 6      |
| 50%      | 0,342       | 0,322       | 0,441        | 2      |




Рисунок 1. Время генерации, фильтрации и сортировки правил при изменении порога достоверности.

Медианное время уменьшается с 0,420 мс при пороге 20% до 0,342 мс при пороге 50%. Разница небольшая, потому что программа в любом случае рассматривает одни и те же разбиения частых наборов. Более высокий порог сокращает число объектов, которые нужно добавить в результат и отсортировать.

Измеренные значения меньше одной миллисекунды и зависят от компьютера и фоновой нагрузки. Они показывают тенденцию для этой реализации, но не являются универсальной оценкой скорости Apriori.

## Количество найденных правил




Рисунок 2. Количество правил при изменении порога достоверности.

Количество правил последовательно сокращается: 164, 99, 65, 34, 19, 6 и 2. Это ожидаемый результат. Любое правило, которое проходит высокий порог, проходит и все более низкие пороги. Поэтому множество правил при увеличении confidence может только уменьшаться.

Порог 20% даёт большой список, в котором сложнее выделить главное. Порог 50% оставляет только два правила. Для содержательного анализа выбран промежуточный порог 40%. Он даёт 19 правил, поэтому список остаётся обозримым и сохраняет несколько разных типов покупательского поведения.

## 5. Список правил и содержательный анализ

Ниже приведены все правила при поддержке 1% и достоверности 40%. Антецедент и консеквент суммарно содержат не более семи объектов. Фактически максимальная длина равна трём, потому что при поддержке 1% частые наборы большей длины в baskets.csv отсутствуют.

| Правило                                         | Поддержка | Достоверность |
|-------------------------------------------------|-----------|---------------|
| говяжий фарш → минеральная вода                 | 4,093%    | 41,655%       |
| говяжий фарш → макароны                         | 4,026%    | 40,977%       |
| оливковое масло → минеральная вода              | 2,760%    | 41,903%       |
| суп → минеральная вода                          | 2,306%    | 45,646%       |
| говяжий фарш, макароны → минеральная вода       | 1,720%    | 42,715%       |
| говяжий фарш, минеральная вода → макароны       | 1,720%    | 42,020%       |
| лосось → минеральная вода                       | 1,706%    | 40,125%       |
| макароны, шоколад → минеральная вода            | 1,640%    | 40,196%       |
| макароны, молоко → минеральная вода             | 1,613%    | 43,682%       |
| молоко, шоколад → минеральная вода              | 1,400%    | 43,568%       |
| шоколад, яйца → минеральная вода                | 1,346%    | 40,562%       |
| молоко, яйца → минеральная вода                 | 1,306%    | 42,424%       |
| замороженные овощи, макароны → минеральная вода | 1,227%    | 43,396%       |
| блинчики, макароны → минеральная вода           | 1,173%    | 45,833%       |
| говяжий фарш, молоко → минеральная вода         | 1,107%    | 50,303%       |
| замороженные овощи, молоко → минеральная вода   | 1,107%    | 46,893%       |
| говяжий фарш, шоколад → минеральная вода        | 1,093%    | 47,399%       |
| макароны, оливковое масло → минеральная вода    | 1,067%    | 44,944%       |
| говяжий фарш, яйца → минеральная вода           | 1,013%    | 50,667%       |

Большинство правил указывает на минеральную воду в консеквенте. Например, правило «суп → минеральная вода» имеет поддержку 2,306% и достоверность 45,646%. Это означает, что оба товара встречаются вместе

примерно в 2,3% всех корзин, а среди корзин с супом минеральная вода присутствует примерно в 45,6% случаев.

Самые достоверные правила связаны с сочетаниями из двух товаров. Для «говяжий фарш, яйца → минеральная вода» достоверность равна 50,667%, а для «говяжий фарш, молоко → минеральная вода» она равна 50,303%. Такие правила могут использоваться для совместного размещения товаров или рекомендаций, однако их поддержка составляет около 1%, поэтому они описывают сравнительно небольшую часть покупок.

Правило «говяжий фарш → макароны» выделяется тем, что его консеквентом является не минеральная вода. Поддержка равна 4,026%, достоверность 40,977%. Это одно из наиболее распространённых правил в списке и оно отражает понятное сочетание продуктов для приготовления основного блюда.

Высокая доля правил с минеральной водой частично объясняется её общей популярностью: она встречается в 23,837% всех корзин. Поэтому confidence нельзя понимать как доказательство причинной связи. Для оценки силы связи полезно дополнительно вычислять lift и сравнивать достоверность с базовой частотой консеквента, хотя это не входило в задание.

## **6. Вывод**

Программа дополнена поиском ассоциативных правил, порогом достоверности, ограничением длины и двумя способами сортировки. Правильность поддержки и достоверности 19 анализируемых правил независимо проверена прямым просмотром корзин. Эксперимент показал, что повышение порога достоверности с 20% до 50% сокращает число правил со 164 до 2 и немного уменьшает время формирования результата.

[1] Agrawal R., Srikant R. Fast Algorithms for Mining Association Rules in Large Databases. VLDB, 1994, страницы с 487 по 499. Текст статьи.